

Arquitectura de Datos en Python y Ciencia Abierta

La velocidad de las frutas · guía de lectura y ejecución

No necesita memorizar código. Necesita reconocer qué entra, qué cambia y qué afirmación produce cada paso.

1 PREGUNTA	12 TRAMOS	500 FILAS SINTÉTICAS	0 PUBLICACIONES REALES
---------------	--------------	-------------------------	---------------------------

SIMULACIÓN DOCENTE Ninguna observación procede de participantes reales. Las señales son ficticias. El caso no valida símbolos de tráfico ni autoriza recomendaciones viales.

El manual acompaña el cuaderno editable. Léalo como una cadena: cada capítulo recibe un objeto, ejecuta una decisión y deja otro objeto auditable.

01 · MAPA

La cadena completa

IDEA CENTRAL Pregunta → evidencia → protocolo → instrumento → dato → análisis → versión → depósito.

Tiempo	Herramienta	Objeto que conserva
00–15	Juego + privacidad	Decisiones iniciales y token aleatorio
15–45	PICO-D	Hipótesis y diseño mixto
45–60	Elicit	Tabla de evidencia verificada
60–75	ResearchRabbit	Red y artículos semilla
75–90	OSF + ética + DMP	Tres contratos alineados
90–105	FAIR	Capas y reglas de acceso
105–120	Git	Commit y etiqueta prereg-v1
120–128	Streamlit	Instrumento probado
128–135	Prolific	Estudio en borrador
135–142	pandas	Conjunto validado
142–165	Jupyter	Contraste reproducido
165–180	GitHub + Zenodo	Release y depósito de demostración

Al terminar

Debe poder explicar qué dato entra en el análisis, qué decisión estaba cerrada antes de verlo y qué archivos jamás llegarían a un repositorio público.

02 · TOKEN ALEATORIO

Privacidad: anónimo frente a quién

Concepto	Criterio operativo	Efecto
Anónimo	No existe una vía razonable de reidentificación.	Fuera del RGPD solo si la anonimización es efectiva e irreversible.
Seudonimizado	La identidad puede recuperarse mediante información adicional separada.	Sigue siendo dato personal.
Codificado/confidencial	La identidad es conocida por el organizador y se oculta a terceros.	No equivale a anonimato.
k-anonimato	Cada combinación de cuasi-identificadores aparece, al menos, k veces.	Reduce singularización; no impide toda inferencia o enlace.

El ejercicio de aula

- No use los últimos dígitos del móvil: son un fragmento real, enlazable y con colisiones.
- Entregue un token aleatorio de cinco cifras. El estudiante conserva la llave.
- El organizador publica el token ganador; quien lo posee decide identificarse para reclamar el premio.
- El token no entra en el CSV analítico ni en GitHub. Se destruye al cerrar el premio.

PRUEBA DE TRES PREGUNTAS Si puede singularizar, enlazar o inferir, la etiqueta «anónimo» exige una revisión técnica.

La minimización pide recoger lo necesario, no lo que resulte cómodo. Este manual no sustituye la revisión jurídica o institucional.

03 · DISEÑO

PICO-D y el contrato experimental

Letra	Pregunta	Decisión del caso
P	¿Quién responde?	Adultos con permiso vigente y español
I	¿Qué condición inicia?	Naranja primero
C	¿Contra qué se compara?	Plátano primero
O	¿Qué medimos y cuándo?	velocidad_primera_kmh
D	¿Qué diseño produce el contraste?	Asignación 1:1 entre sujetos para el primario

HIPÓTESIS CONGELADA

```

H0: E[velocidad_primera | naranja_primero] <=
    E[velocidad_primera | platano_primero]

H1: E[velocidad_primera | naranja_primero] >
    E[velocidad_primera | platano_primero]

```

El diseño es mixto: cada persona responde a dos símbolos. El contraste confirmatorio, sin embargo, es entre sujetos y usa solo la primera decisión. La segunda ya conoce el otro símbolo y queda para anclaje, contraste y coordinación.

ESCALA Opciones: 30, 50, 70, 90, 110 y 130 km/h. Confianza 0–100. Texto final opcional y restringido.

Estimando: Δ = media inicial de naranja – media inicial de plátano. Una media no implica que exista una velocidad correcta.

04 · CONFIRMATORIO Y SECUNDARIO

Diseñar antes de analizar

Uso	Variables	Pregunta
Confirmatorio	símbolo_primero + velocidad_primera_kmh	¿La media inicial de naranja es mayor?
Secundario	ambas velocidades + orden	¿Hay anclaje, contraste o covariación?
Secundario	distribución 2×6	¿Cambian las categorías completas?
Secundario	$\Sigma p(v)^2$	¿Qué símbolo concentra más coincidencias?
Exploratorio	texto abierto → Regex	¿Qué motivos aparecen?

Regla temporal

DESIGUALDAD ESTRICTA

```
speeders = (tiempo_primera_s < 2.0) | (tiempo_segunda_s < 2.0)
analitico = datos.loc[~speeders].copy()
```

- 1,999 s se excluye.
- 2,000 s permanece.
- La regla no mira el grupo, la velocidad ni la significación.
- La exclusión analítica no modifica el pago base ni la bonificación.

DECISIÓN Medir bien consiste en cerrar puertas antes de saber cuál conduce al resultado deseado.

05 · LITERATURA

Elicit: una tabla que obliga a verificar

CONSULTA COPIABLE

Which experimental studies have measured whether people associate fruits or foods with fast versus slow?

Columna	Qué debe contener
Población y N	Muestra analizada y denominador
Diseño y tarea	Asignación, estímulos y procedimiento
Resultado	Recuento, estimación e incertidumbre
Límite	Qué inferencia no permite el estudio
Trazabilidad	DOI y página/sección/tabla/figura
Estado	VERIFICADA o PENDIENTE

Woods et al. (2013) observaron asociaciones limón–rápido y ciruela pasa–lento. Es un antecedente. No midieron naranja frente a plátano, km/h, coordinación incentivada ni seguridad vial.

REGLA Elicit localiza y estructura. El artículo original decide qué celda sobrevive.

ResearchRabbit: la red no reemplaza la lectura

Semilla	Rama	Función
Woods et al. (2013)	Correspondencia	Dato alimento–velocidad
Spence (2023)	Síntesis	Contexto sobre correspondencias
Mehta et al. (1994)	Coordinación	Mecanismo de punto focal
Shinar et al. (2003)	Límite	Variación intercultural en señales

- Refs lleva hacia trabajos anteriores.
- Cited by muestra trabajos que citan la semilla.
- Los vecinos sirven para ampliar la búsqueda, no para aceptar conclusiones.
- Todo candidato nuevo entra primero en PENDIENTES_VERIFICAR.

LÍMITE Citar juntos dos artículos no convierte sus variables en equivalentes.

Prerregistro, ética y DMP

Contrato	Pregunta	Salida
Prerregistro	¿Qué analizamos?	N, primario, exclusión, test, alfa y secundarios
Ética	¿Qué podemos pedir?	Información, consentimiento, riesgos, pago y retirada
DMP	¿Qué puede salir?	Inventario, acceso, transformación, licencia y retención

- N=500, asignación 1:1, sin análisis intermedios.
- Welch unilateral, equal_var=False, alternative='greater', $\alpha=0,05$.
- No se solicita número de permiso, IP, geolocalización ni fotografía.
- El texto abierto es opcional, restringido y se revisa antes de derivar categorías.
- Toda desviación conserva fecha, motivo y acceso previo a resultados.

AUDITORÍA CRUZADA Si velocidad_primera_kmh, 2.0, HMAC o bonificación cambian de significado entre fichas, el sistema tiene una grieta.

FAIR: abierto bajo reglas

Capa	Función	Nunca confundir con
Bruta	Preservar la entrada original	Archivo de trabajo
Restringida	Guardar enlaces, texto, tiempos exactos y pagos	Repositorio público
Analítica	Contener transformaciones y variables derivadas	Original inmutable
Pública	Permitir reutilización de datos sintéticos minimizados	Todo el proyecto

Encontrable exige metadatos. Accesible exige condiciones. Interoperable exige formatos y vocabulario. Reutilizable exige licencia, diccionario, procedencia y transformaciones.

- CSV UTF-8 para tablas; JSON para resultados; PNG/SVG para figuras; Markdown/PDF para lectura.
- CC BY 4.0 para documentación y datos sintéticos; MIT para código propio.
- PROLIFIC_PID, SESSION_ID, HMAC, timestamps exactos, texto abierto, pair_id y pagos permanecen fuera.

PRINCIPIO FAIR describe el recorrido del dato. No es sinónimo de acceso irrestricto.

09 · TRAZABILIDAD

Carpetas y Git

ESTRUCTURA MÍNIMA

```
proyecto/  
├── 01_literatura/  
├── 02_protocolo/  
├── 03_datos_raw/  
├── 04_datos_publicos/  
├── 05_analisis/  
└── 06_publicacion/
```

SECUENCIA COPIABLE

```
git status --short  
git diff  
git add 02_PROTOCOLO 04_DATOS/metadata  
git diff --staged  
git commit -m "protocol: freeze design and data rules"  
git tag -a prereg-v1 -m "Congelación docente previa al dato"  
git log --oneline --decorate -5
```

Las carpetas separan estados. Git conserva diferencias. Un commit atómico contiene una decisión; la etiqueta identifica el estado previo al dato.

HÁBITO Inspeccione `git diff --staged` antes de confirmar. Para deshacer historia compartida, use un nuevo commit o `git revert`.

10 · INSTRUMENTO Y MUESTRA

Streamlit y Prolific

Sistema	Responsabilidad	Prueba mínima
Streamlit	Ejecutar consentimiento, orden, respuestas y guardado	Recargar no cambia orden ni duplica envío
Prolific	Reclutar, pagar y devolver a plataforma	Preview con parámetros y retorno
Almacenamiento	Persistir una sesión una sola vez	Fallo impide redirección

PARÁMETROS EXTERNOS

```
https://[DOMINIO_APP]/?modo=docente
&PROLIFIC_PID={{%PROLIFIC_PID%}}
&STUDY_ID={{%STUDY_ID%}}
&SESSION_ID={{%SESSION_ID%}}
```

- Duración 4 minutos; 500 plazas; pago base £0.60 = £9/h.
- Edad 18+, español fluido, ordenador y permiso vigente por autodeclaración.
- El bono equivalente a 0,50 € va aparte y nunca corrige un pago base insuficiente.
- El estudio docente permanece en borrador: no publicar ni reservar presupuesto.

SEPARACIÓN La aplicación implementa el protocolo. Prolific ejecuta el reclutamiento. Ninguna plataforma reemplaza el diseño.

11 · DATOS

Leer pandas sin memorizar Python

1 · CARGAR Y MIRAR

```
import pandas as pd

datos = pd.read_csv(RUTA_CSV)
print(datos.shape)
display(datos.head(3))
datos.info()
```

2 · FILTRAR CON LA REGLA CONGELADA

```
 analisis = datos.loc[
    (datos["tiempo_primera_s"] >= 2.0)
    & (datos["tiempo_segunda_s"] >= 2.0)
].copy()
```

3 · AGRUPAR Y CALCULAR MEDIAS

```
resumen = (
    analisis.groupby("orden")
    .agg(n=("velocidad_primera_kmh", "size"),
         media=("velocidad_primera_kmh", "mean"))
    .round(2)
)
```

Símbolo	Lectura
=	Asigna un nombre; no compara
[]	Selecciona columna o condición
.función()	Aplica una operación al objeto de la izquierda
& /	Combina condiciones con Y / O
#	Introduce un comentario

12 · PYTHON

Jupyter: leer una tubería de análisis

Paso	Pregunta de lectura	Objeto
Importar	¿Qué bibliotecas entran?	pd, np, sns, stats, smf
Cargar	¿Qué archivo se abre?	DataFrame datos
Validar	¿Qué error detiene el flujo?	Contrato satisfecho
Filtrar	¿Qué filas sobreviven?	analisis
Agrupar	¿Qué media obtiene cada grupo?	resumen
Mostrar	¿Qué distribución representa la figura?	histograma/barras
Contrastar	¿Qué test estaba escrito?	Welch unilateral
Modelizar	¿Qué está a la izquierda de ~?	resultado OLS

CONTRASTE CONFIRMATORIO

```
resultado = stats.ttest_ind(
    grupo_naranja,
    grupo_platano,
    equal_var=False,
    alternative="greater",
)
```

REGRESIÓN SECUNDARIA

```
modelo = smf.ols(
    "velocidad_naranja_kmh ~ velocidad_platano_kmh + C(orden)",
    data=analisis,
).fit(cov_type="HC3")
```

CAMBIO SEGURO Cambiar un código hexadecimal modifica la figura. No modifica el CSV, las medias ni el test.

13 · SIMULACIÓN

Leer el resultado sin ampliar la afirmación

Medida	Resultado sintético
Recibidos / válidos	500 / 480; 240 por grupo
Media naranja primero	89,25 km/h
Media plátano primero	68,67 km/h
Diferencia	20,58 km/h
IC 95 %	17,69–23,48
Welch	$t \approx 13,96$; $p < 0,001$
Cohen d	$\approx 1,27$
Coordinación Σp^2	0,377 naranja; 0,328 plátano
OLS secundaria	pendiente $\approx 0,46$; orden $\approx +3,23$ km/h

FRASE PERMITIDA En esta simulación y bajo esta tarea de coordinación, el grupo que vio primero la naranja asignó una velocidad inicial media mayor.

No puede afirmar

- que la naranja deba usarse como señal rápida;
- que conductores reales responderán igual;
- que el resultado funciona en cualquier país o idioma;
- que la tarea mejora la seguridad vial;
- que los análisis secundarios sustituyen al primario.

14 · PUBLICACIÓN

GitHub, release, Zenodo y DOI

Capa	Qué aporta	Qué no aporta
Git	Historia local de cambios	Acceso remoto
GitHub	Sincronización e inspección remota	Permanencia científica por sí sola
Release	Nombre y paquete de una versión	Depósito independiente
Zenodo	Conservación, metadatos y DOI al publicar	Permiso para publicar datos restringidos

REVISIÓN ANTES DE SALIR

```
git status --short
git grep -n -I -E "PROLIFIC_PID|SESSION_ID|hmac|pair_id"
git tag -a v1.0.0-demo -m "Release docente"
# Después: release en borrador y depósito Sandbox
```

- Genere el paquete desde una lista positiva de archivos publicables.
- Incluya CITATION.cff, licencias y manifiesto SHA-256.
- Guarde el release como borrador y el depósito en Sandbox.
- Un DOI se vuelve citable cuando el depósito apropiado se publica; este curso se detiene antes.

CADENA commit → tag → release → depósito → DOI

15 · QUÉ CONSERVAR

Caja de herramientas

Herramienta	Acción mínima	Evidencia
PICO-D	Nombrar población, comparación y outcome	Hipótesis refutable
Elicit	Extraer y verificar	Tabla con ubicación
ResearchRabbit	Navegar Refs/Cited by	Red por funciones
OSF	Crear borrador	Protocolo congelable
FAIR	Separar capas y accesos	DMP operativo
Git	Inspeccionar y confirmar	Commit atómico
Streamlit	Probar flujo y persistencia	Instrumento
Prolific	Auditar Preview	Borrador de muestra
pandas	Cargar, validar, agrupar	DataFrame analítico
Jupyter	Ejecutar y leer salidas	Notebook
GitHub + Zenodo	Nombrar y depositar	Versión citable

Cinco preguntas para leer cualquier análisis

- ¿Qué archivo entra?
- ¿Qué regla elimina o transforma filas?
- ¿Qué variable responde la pregunta?
- ¿Qué estimación y qué incertidumbre salen?
- ¿Qué afirmación sigue prohibida?

CRITERIO Una herramienta entra en su caja cuando deja un objeto que otra persona puede inspeccionar.

Literatura y documentación primaria

- [Reglamento \(UE\) 2016/679 \(RGPD\)](#)
- [WP29 \(2014\), Opinion 05/2014 on Anonymisation Techniques](#)
- [Woods et al. \(2013\), Fast Lemons and Sour Boulders](#)
- [Mehta, Starmer y Sugden \(1994\), The Nature of Salience](#)
- [Shinar et al. \(2003\), Traffic Sign Symbol Comprehension](#)
- [Spence \(2023\), Visual Shape–Taste Crossmodal Correspondences](#)
- [Wilkinson et al. \(2016\), FAIR Guiding Principles](#)
- [Elicit Help · Columns](#)
- [ResearchRabbit · Refs y Cited by](#)
- [OSF Support · Registrations & Preregistrations](#)
- [Git · Recording Changes](#)
- [Streamlit Documentation](#)
- [Prolific · Payment model](#)
- [pandas · read_csv](#)
- [SciPy · ttest_ind](#)
- [GitHub Docs · Managing releases](#)
- [Zenodo Help · Deposit y Sandbox](#)

Parece indicar que el caso funciona como demostración metodológica: su valor está en la arquitectura completa, no en la fuerza de una metáfora vial.